

석 사 학 위 논 문

RSMA를 적용한 5G MIMO
네트워크에서의 강화학습 기반
자원 최적화 연구

김지명

부산대학교 대학원

정보융합공학과

2026년 8월

RSM을 전영한 5G MIMO 네트워크에서의
강화학습 기반 자원 최적화 연구

김지명

2026년
8월

RSMA를 적용한 5G MIMO 네트워크에서의 강화학습 기반 자원 최적화 연구

이 논문을 공학석사 학위논문으로 제출함

김지명

부산대학교 대학원

정보융합공학과

지도교수 유영환

김지명의 공학석사학사 학위논문을 인준함

2026년 월 일

위원장	김종덕	인
위원	김원석	인
위원	유영환	인

차 례

<제목 차례>

1. 서론	1
1.1. 연구 배경	1
1.2. 연구 목적	5
1.3. 연구의 기여점	5
1.4. 논문 개요	5
2. 관련 연구	1
2.1. RSMA 자원 최적화	1
2.2. MLB	5
3. 시스템 모델	1
3.1. 네트워크 및 채널 모델	1
3.2. 저복잡도 사용자 선택 기반 RSMA 전송 모델	5
3.3. A3 기반 핸드오버 모델	5
3.4. 처리량 및 부하 모델	5
3.5. 문제 정의	5
4. TD-MPC2 기반 자원 최적화 프레임워크	1
4.1. 멀티 타임스케일 교차 계층 제어 구조	1
4.2. MDP 정식화	5
4.2.1 상태 공간	5
4.2.2 행동 공간	5
4.2.3 보상 함수	5
4.3. TD-MPC2 알고리즘	5
4.3.1 월드 모델	5
4.3.2 잠재 공간 기반 계획	5

4.3.3 네트워크 최적화 및 파라미터 갱신	5
5. 실험 방법 및 결과	1
5.1. 실험 방법	1
5.2. 실험 결과	5
5.2.1 시스템 성능 평가 및 비교 분석	5
5.2.2 제안 기법의 효용성 분석	5
5.2.3 이질 트래픽 환경에서의 일반화 성능 평가	5
6. 결론 및 토의	1

<표 차례>

[표 1] 시뮬레이션 파라미터 설정	12
[표 2] TD-MPC2 하이퍼파라미터 설정	12
[표 3] 이질 트래픽 그룹 파라미터 설정	12

<그림 차례>

[그림 1] RSMA 기반 다중 셀 MIMO 하향링크 시스템 모델	12
[그림 2] 제안하는 TD-MPC2 기반 멀티 타임스케일 자원 최적화 프레임워크	12
[그림 3] 학습 단계에 따른 에피소드 리턴 수렴 곡선	12
[그림 4] 시스템 처리량 비교	12
[그림 5] 셀 간 부하 불균형 비교	12
[그림 6] HOF 발생률 비교	12
[그림 7] 개별 제어 동작에 따른 처리량 비교	12
[그림 8] 개별 제어 동작에 따른 부하 불균형 비교	12
[그림 9] 개별 제어 동작에 따른 HOF 발생률 비교	12
[그림 10] 보상 가중치 변화에 따른 처리량 및 부하 불균형 성능 변화	12
[그림 11] 이질 트래픽 환경에서의 처리량 비교	12

[그림 12] 이질 트래픽 환경에서의 부하 불균형 비교	12
[그림 13] 이질 트래픽 환경에서의 HOF 발생률 비교	12

RSMA를 적용한 5G MIMO 네트워크에서의 강화학습 기반 자원 최적화 연구

김지명

부산대학교 대학원 정보융합공학과

요약

5G 다중입출력(Multiple-Input Multiple-Output, MIMO) 네트워크 환경에서는 사용자 이동에 따른 핸드오버와 셀 간 간섭으로 인해 네트워크 상태가 동적으로 변화하며, 이에 대응하는 제어 기법이 요구된다. 비직교 다중접속(Rate-Splitting Multiple Access, RSMA)은 간섭 완화와 전송 효율 향상을 동시에 고려할 수 있는 기술로 주목받고 있으나, 수치 해석 기반의 기존 자원 최적화 방식은 높은 연산 복잡도를 수반한다. 또한, 물리계층 제어만으로는 네트워크 자원의 효율적인 최적화가 어렵고, 사용자 접속 및 부하 분산을 포함하는 네트워크 계층 제어를 함께 고려할 필요가 있다. 본 논문에서는 이러한 한계를 해결하기 위해 비례 공정성(proportional fairness) 지표와 채널 공간 상관도(channel spatial correlation)를 반영한 저복잡도 사용자 선택 기반 RSMA 구조를 채택하고, 이를 기반으로 5G MIMO 네트워크에서 강화학습(reinforcement learning)을 이용한 교차 계층 자원 최적화 기법을 제안한다. 제안 기법은 셀 개별 오프셋(Cell Individual Offset, CIO)과 RSMA 분할 비율(split ratio)을 공동 최적화하여 네트워크 처리율과 부하 분산 성능을 동시에 향상하는 것을 목표로 한다. 성능 평가 결과, 제안 기법은 기존 모델 프리(model-free) 강화학습 알고리즘 대비 높은 샘플 효율성을 보였으며, 기준 환경 대비 처리량을 23.25% 향상했다. 또한 부하 불균형과 핸드오버 실패율을 각각 28.71%, 71.56% 감소시켜 시스템 신뢰성을 대폭 개선하였으며, 이질적 트래픽 환경에서도 안정적인 자원 제어 성능을 달성하여 본 프레임워크의 강건성(robustness)을 입증하였다.

1. 서론

1.1. 연구 배경

최근 이동통신 네트워크는 대용량 데이터 트래픽, 이질적인 서비스 품질 요구, 그리고 대규모 접속 수요를 동시에 수용해야 하는 방향으로 발전하고 있다 [1, 2]. 이러한 환경에서는 제한된 주파수 자원 안에서 높은 스펙트럼 효율을 달성하는 동시에, 사용자(user) 분포와 채널 조건의 시변성에 적응적으로 대응할 수 있는 전송 및 자원관리 구조가 요구된다. 특히 다중 셀 다중사용자 다중입출력(Multiple-Input Multiple-Output, MIMO) 환경에서는 사용자 배치, 채널의 방향성과 세기, 송신단 채널상태정보(Channel State Information at the Transmitter, CSIT)의 정확도에 따라 간섭 구조가 크게 달라지며, 시스템은 과부하(overloaded) 상태에서도 운용될 수 있다. 따라서 기존의 직교 자원 분할만으로는 이러한 다양한 운용 조건에서 일관된 성능을 확보하기 어렵고, 보다 유연한 다중접속 및 간섭 관리 기법이 요구된다.

다중 안테나 하향링크에서 대표적인 전송 방식으로는 공간 분할 다중접속(Space Division Multiple Access, SDMA)과 비직교 다중접속(Non-Orthogonal Multiple Access, NOMA)이 존재한다. 전자는 간섭을 가능한 한 억제한 뒤 잔여 간섭을 주로 잡음으로 처리하는 방향으로 설계되는 반면, 후자는 더 많은 간섭을 복호하는 방향으로 설계된다. 이에 비해 전송률 분할 다중접속(Rate-Splitting Multiple Access, RSMA)은 간섭의 일부는 복호하고 나머지는 잡음으로 처리하는 구조를 취함으로써 두 방식 사이의 보다 넓은 설계 공간을 제공한다 [3, 4]. 다수의 선행 연구는 RSMA가 다양한 사용자 배치, 네트워크 부하, 그리고 불완전한 CSIT 환경에서 SDMA와 NOMA에 비해 우수하거나 보다 강건한 성능을 달성할 수 있음을 보고하였다 [5, 6]. 또한 구현 측면에서 가장 널리 고려되는 1계층 RSMA(1-layer RSMA)는 하나의 공통 스트림(common stream)과 사용자별 개별 스트림(private stream)으로 구성되며, 각 수신기에서 한 차례의 순차적 간섭 제거(Successive Interference Cancellation, SIC)만을 요구한다는 점에서 비교적 단순한 수신 구조를 갖는다. 이러한 이유로 1-layer RSMA는 다수의 연구에서 기본 구조로 채택되어 왔다.

그러나 1-layer RSMA는 구조가 단순한 만큼 분명한 제약도 내포한다. 공통 스트림은 이를 복호하는 모든 사용자가 성공적으로 복호할 수 있어야 하므로, 공통 스트림의 전송률은 결국 가장 불리한 사용자의 달성 가능 전송률에 의해 제한된다. 사용자 간 채널 이

질성이 크거나 공통 복호 대상 집합이 넓은 경우, 이러한 특성은 공통 스트림이 시스템 성능의 병목으로 작용하게 만든다. 이러한 한계를 완화하기 위하여 계층적 RSMA나 일반화된 RSMA와 같이 복수의 공통 스트림을 활용하는 구조가 제안되었으나, 사용자 수가 증가할수록 스트림 구성과 복호 구조는 더욱 복잡해진다. 기존의 RSMA 자원 할당 연구들은 주로 WMMSE(Weighted Minimum Mean Square Error)와 같은 복잡한 반복적 수치 최적화(iterative numerical optimization) 기법에 의존해 왔으며, 최근 연구들 역시 이러한 프리코딩 최적화가 실제 하드웨어 구현이나 온라인 운용에 적용하기에는 연산 부담이 크다는 점을 지적하고 있다 [7, 8, 9]. 결국 다중 셀의 동적 환경을 고려할 때에는, 공통 스트림 병목을 완화하면서도 반복 최적화 부담을 줄일 수 있는 저복잡도 RSMA 구조를 검토할 필요가 있다.

한편, 셀 내부 전송 구조의 개선만으로는 다중 셀 환경에서 나타나는 네트워크 수준의 동적 변화에 충분히 대응하기 어렵다. 실제 시스템의 성능은 단기적인 물리계층 전송률 뿐만 아니라, 셀 간 사용자 분포, 핸드오버(handover) 양상, 그리고 부하 편중의 정도에 의해서도 크게 영향받는다. 3GPP에서는 이러한 불균등한 트래픽 부하 문제에 대응하기 위한 방식으로 이동성 부하 분산(Mobility Load Balancing, MLB)을 다루고 있으며 [10], 이 과정에서 히스테리시스(hysteresis), 타임-투-트리거(Time-to-Trigger, TTT), 셀 개별 오프셋(Cell Individual Offset, CIO)과 같은 제어 변수가 활용된다. 그중 CIO는 단말의 핸드오버 결정 경계를 조정하여 혼잡 셀의 사용자를 인접 셀로 유도하는 대표적인 제어 변수로 사용된다.

이상의 논의를 종합하면, 다중 셀 MIMO 네트워크의 성능은 물리 계층의 간섭 제어 능력과 셀 간 트래픽 분포에 의해 복합적으로 결정된다. 그러나 이 두 요소를 분리하여 다루는 기존 접근에는 구조적 제약이 존재한다. RSMA 중심의 물리 계층 최적화는 셀별 사용자 분포와 핸드오버 양상을 직접 제어하지 못하며, 반대로 CIO 기반의 부하 분산은 공통 스트림 병목이나 공통·개별 스트림 간 전력 분할과 같은 RSMA 고유의 물리계층 특성을 반영하지 못한다. 또한 동적으로 변화하는 네트워크 환경에서 복잡한 반복 최적화를 매 시점 수행하는 방식은 실시간 운용에 부담이 될 수 있다. 이에 본 연구는 저복잡도 RSMA 구조를 바탕으로, 물리 계층의 분할비 조정과 네트워크 계층의 CIO 제어를 연계하는 교차 계층(cross-layer) 제어 구조를 다루고자 한다. 구체적인 연구 목적은 다음 절에서 제시한다.

1.2. 연구 목적

본 연구의 최종 목적은 다중 셀 다중사용자 MIMO 하향링크 네트워크 환경에서, 물리 계층의 RSMA 전송 구조와 네트워크 계층의 부하 분산 제어를 연계하여 시스템 성능을 통합적으로 개선하는 교차 계층 최적화 구조를 설계하는 데 있다. 이를 달성하기 위한 구체적인 세부 연구 목표는 다음과 같다.

- (1) 저복잡도 RSMA 물리 계층 구조 설계: 매 시점 막대한 연산량이 요구되는 전체 최적화를 대체하기 위해, 비례 공정성(Proportional Fair, PF) 지표와 채널의 공간 상관관계를 결합한 탐욕적 준직교 사용자 선택(Semi-Orthogonal User Selection, SUS) 기반의 저복잡도 RSMA 전송 구조를 채택한다.
- (2) 다중 시간 스케일 교차 계층 제어 문제 정식화: 제안하는 저복잡도 RSMA 구조를 바탕으로, 동적인 네트워크 상태 변화에 맞춰 물리계층의 RSMA 분할 비율과 네트워크 계층의 CIO를 함께 적응시키는 학습 기반의 공동 제어 문제를 구성한다.
- (3) 모델 기반 강화학습 적용 및 성능 검증: 서로 다른 제어 주기를 갖는 의사결정 변수들을 최적화하기 위해 모델 기반 강화학습(model-based reinforcement learning) 알고리즘인 Temporal Difference Learning for Model Predictive Control 2 (TD-MPC2)를 도입하며, 이를 통해 전체 시스템의 처리율(throughput) 향상 및 셀 간 부하 표준편차 감소 효과를 검증한다.

1.3. 연구의 기여점

본 논문의 주요 기여점은 다음과 같다.

첫째, 1-layer RSMA 구조에서 발생하는 공통 스트림 병목 현상과 자원 할당의 높은 계산 복잡도 문제를 완화하기 위하여, 사용자별 가중치와 채널 간의 기하학적 특성을 고려한 저복잡도 RSMA 전송 구조를 제안하였다. 이를 통해 시스템 과부하 조건에서도 다중 사용자 제어를 위한 자유도를 효과적으로 확보하였다.

둘째, 물리계층의 RSMA 분할 비율과 네트워크 계층의 CIO를 유기적으로 연계하여, 시스템 처리량 향상과 셀 간 부하 균형을 동시에 달성할 수 있는 교차 계층(cross-layer) 공동 제어 모델을 정식화하였다.

셋째, 제어 변수별 상이한 갱신 주기를 반영하기 위해 다중 시간 척도 제어 구조를 도입하였으며, 이를 중앙집중형 마르코프 결정 과정(Markov Decision Process, MDP)로 구성하여 잠재 공간 내 동역학 학습이 가능한 TD-MPC2 기반의 모델 기반 강화학습 알고리즘을 적용하였다.

넷째, 시스템 레벨 시뮬레이션을 통해 기존 모델 프리(model-free) 알고리즘 대비 우수한 샘플 효율성과 수렴 성능을 입증하였다. 특히 부하 분산을 통한 핸드오버 실패(Handover Failure, HOF) 개선 및 이질적 트래픽 환경에서의 강건성을 확인하여, 제안하는 제어 구조의 실제 네트워크 운용 측면에서의 유효성을 검증하였다.

1.4. 논문 개요

본 논문의 구성은 다음과 같다.

제2장에서는 RSMA 전송 기술, 네트워크 부하 분산 기법, 그리고 강화학습 기반의 자원 최적화와 관련된 국내외 선행 연구를 고찰한다.

제3장에서는 다중 셀 다중사용자 MIMO 하향링크 환경을 정의하고, 이를 분석하기 위한 통신 시스템 모델 및 확률론적 채널 모델을 기술한다.

제4장에서는 본 논문에서 제안하는 저복잡도 RSMA 구조의 상세 설계와 교차 계층 제어 문제의 정식화 과정을 설명하며, TD-MPC2를 활용한 에이전트(agent)의 학습 및 계획 메커니즘을 상술한다.

제5장에서는 시뮬레이션 환경 설정 및 성능 평가 지표를 제시하고, 제안 기법과 베이스라인 알고리즘 간의 비교 분석을 통해 정량적·정성적 성능을 평가한다.

마지막으로 제6장에서는 본 연구의 핵심 결과를 요약하고, 연구의 한계점 및 이를 보완하기 위한 향후 연구 방향을 제시하며 논문을 마무리한다.

2. 관련 연구

본 장에서는 제안 기법과 관련된 기존 연구를 검토한다. 2.1절에서는 RSMA의 자원 최적화 및 사용자 선택 기법의 발전과 한계를 분석하고, 2.2절에서는 이동성 부하 분산에 적용된 데이터 기반 제어 기법의 발전과 한계를 분석한다. 각 절의 말미에서 본 논문이 해결하고자 하는 연구 공백을 도출한다.

2.1. RSMA 자원 최적화

5G 네트워크에서 스펙트럼 효율성 향상과 간섭 제어를 위해 RSMA가 핵심 전송 기술로 주목받고 있다. Joudeh와 Clerckx는 사용자 메시지를 공통부분과 개별 부분으로 분할하여 간섭을 부분적으로 디코딩하고 부분적으로 잡음으로 처리하는 RSMA 프레임워크를 제안하였으며 [11], 이를 통해 기존의 SDMA, OMA, NOMA를 특수 사례로 포괄하는 일반적 다중접속 구조를 확립하였다 [3, 4]. 특히 송신 안테나 수 대비 사용자 수가 초과하는 과부하 조건에서 RSMA는 SDMA의 자유도(degree of freedom) 한계를 극복하고, NOMA 대비 유연한 간섭 관리를 제공하는 것으로 입증되었다 [4].

RSMA의 다중 사용자 가중 합 전송률(weighted sum-rate)을 최대화하는 문제는 본질적으로 비볼록(non-convex) 최적화 문제이다. 공통 스트림과 개별 스트림 간의 전력 분할 및 빔포밍 설계를 동시에 수행해야 하므로 기존 SDMA보다 설계 공간이 복잡하며, 기존 연구에서는 이를 해결하기 위해 가중 최소평균제곱오차(weighted minimum mean square error) 알고리즘과 교대 최적화(alternating optimization) 기법을 주로 채택하였다. [3, 12]. 그러나 이러한 반복적 수치 최적화는 안테나 수와 사용자 수가 증가할수록 연산 복잡도가 급격히 증가하여 실시간 자원 할당을 곤란하게 한다 [7]. 특히 1-layer RSMA에서는 공통 스트림의 전송률이 모든 수신 사용자 중 가장 열악한 채널 조건에 의해 제한되므로, 어떤 사용자를 공통 스트림 디코딩 그룹에 포함할지가 전체 시스템 성능에 직결된다.

이러한 수치 해석적 알고리즘의 복잡도를 완화하기 위해 선형 프리코딩을 결합하거나 반복 연산 횟수를 제한한 저복잡도 1-layer RSMA 기법들이 제안되었다 [8, 9]. 그러나 단일 셀 내의 전체 대기 사용자를 대상으로 공통 스트림 전력을 최적화하는 것은 여전히 높은 오버헤드를 수반하므로, 공간적 간섭을 억제할 수 있는 최적의 사용자 그룹을

구성하는 사용자 선택(user selection) 기법이 필수적으로 병행되어야 한다. 대표적으로 Yoo와 Goldsmith가 제안한 반직교 사용자 선택(SUS) [13]은 채널 방향의 직교성과 채널 이득을 동시에 고려하여 탐욕적으로 사용자를 선별함으로써 공간 다중화 이득을 보존하면서도 프리코딩 설계 복잡도를 대폭 감소시킨다. 최근에는 이러한 SUS 기반 사용자 선택을 RSMA 환경에 확장하거나 [14], 유전 알고리즘과 결합하여 스케줄링 연산량을 다항 시간 내로 단축한 연구도 진행되었다 [15].

그러나 이러한 저복잡도 사용자 선택 기법들은 매 전송 시간 간격(transmission time interval)마다 순간적인 채널 상태 정보(channel state information)와 기하학적 직교성만을 스케줄링 지표로 평가한다. 이는 채널 상태가 양호한 셀 중앙 사용자에게 자원이 편중되는 결과를 초래하며, 셀 경계 사용자들이 스케줄링에서 지속적으로 배제되는 기아 현상(starvation)을 야기한다. 5G 통신 시스템에서는 사용자의 과거 평균 전송률 대비 현재 예측 전송률의 비율을 반영하는 PF 지표를 통해 장기적 공평성을 확보해 왔으나 [16], RSMA에서는 채널 상태가 열악한 사용자를 스케줄링 그룹에 포함할 경우 공통 스트림 전송률이 해당 사용자의 디코딩 한계로 하향되어 셀 전체의 성능이 급감하는 구조적 딜레마가 존재한다. 이로 따라 기존의 저복잡도 RSMA 스케줄링에서는 PF 지표가 통합되지 못하였다. 나아가, 상기한 RSMA 자원 최적화 연구들은 단일 셀 환경에서의 물리 계층 성능 향상에 초점을 맞추고 있어, 다중 셀 간 부하 불균형과 같은 네트워크 계층의 문제를 고려하지 않았다. 따라서, PF 지표와 채널 공간 상관도를 공동으로 고려하는 저복잡도 RSMA 사용자 선택 구조의 설계와 함께, RSMA의 물리 계층 간섭 제어 능력을 네트워크 계층의 자원 관리와 유기적으로 결합하는 교차 계층 접근이 요구된다.

2.2. MLB

다중 셀 네트워크에서는 트래픽의 공간적, 시간적 불균형에 대응하고 시스템 전체의 처리량을 최적화하기 위해 MLB가 핵심적인 역할을 수행한다. 3GPP 표준에서 MLB는 CIO나 TTT 파라미터를 조정하여 과부하 셀의 사용자를 인접 셀로 오프로딩하는 방식으로 동작한다 [17]. 초기 연구들은 주로 기지국(base station) 자원 블록(Physical Resource Block, PRB) 사용률을 기반으로 한 규칙 기반 알고리즘이나 퍼지 제어(fuzzy logic control) 기법을 채택하였다 [18]. 그러나 규칙 기반 접근은 임계값과 제어 규칙을 사전에 설정해야 하므로 동적인 트래픽 변동에 유연하게 적응하지 못하며, 공격적인 부

하 분산 시 발생하는 핸드오버 불안정성을 효과적으로 억제하지 못하는 한계가 있다.

규칙 기반 접근의 이러한 한계를 극복하기 위해 데이터 기반의 기계학습(machine learning) 기법이 도입되었다. 지도학습 기반의 접근에서는 과거 네트워크 로그로부터 부하 패턴을 학습하여 핸드오버 트리거 파라미터를 예측하거나 [19], 트래픽 수요를 사전에 예측하여 사전적 부하 재분배를 수행하는 기법이 제안되었다 [20]. 그러나 지도학습 방식은 최적 레이블의 사전 확보가 필요하고, 네트워크 환경의 비정상성(non-stationarity)으로 인해 학습된 모델의 일반화 성능이 시간에 따라 저하되는 문제가 존재한다.

이러한 제약을 해소하기 위해 환경과의 상호작용을 통해 최적 정책을 점진적으로 학습하는 강화학습이 부하 분산에 적용되기 시작하였다. 초기에는 Q-learning 기반의 테이블 형태 에이전트가 CIO 조정에 활용되었으며 [21], 이후 상태 공간의 확장에 대응하기 위해 DQN(Deep Q-Network), DDPG(Deep Deterministic Policy Gradient) 등의 심층 강화학습 기법이 적용되었다 [22]. 최근에는 PPO(Proximal Policy Optimization)를 기반으로 다중 셀의 CIO와 핸드오버 파라미터를 동시에 최적화하거나 [23], 다중 에이전트 강화학습(multi-agent reinforcement learning)을 통해 각 기지국이 분산적으로 부하 분산 정책을 학습하는 연구도 활발히 진행되고 있다 [24].

그러나 이러한 강화학습 기반 연구들은 환경의 전이 역학(transition dynamics)에 대한 사전 지식 없이 시행착오를 통해 정책을 학습하는 모델 프리 방식에 국한되어 있다. 모델 프리 방식은 학습 초기의 무작위 탐색 과정에서 부적절한 CIO 조작을 유발하여 핸드오버 불안정을 초래할 수 있으며, 비정상성 채널 환경에서 수렴에 필요한 데이터 샘플량이 과도하여 실시간 정책 적응에 제약을 지닌다 [23]. 이러한 샘플 비효율성과 탐색 불안정성을 근본적으로 해결하기 위해, 잠재 공간 내에서 환경의 역학 모델을 학습하고 이를 기반으로 미래 궤적을 사전 예측하는 모델 기반 강화학습이 주목받고 있다 [25, 26, 27]. 실제로 통신 분야에서도 환경 모델을 통해 가상 경험을 생성하여 샘플 요구량을 절감하거나 [29], 네트워크 시뮬레이터를 월드 모델로 활용하여 정책을 사전 학습하는 접근이 탐색적으로 연구되고 있다 [28]. 그러나 이러한 시도들은 전력 제어나 스케줄링과 같은 단일 계층 문제에 한정되어 있으며, MLB와 같은 네트워크 계층의 이동성 관리에 모델 기반 강화학습을 적용한 사례는 현재까지 보고되지 않고 있다.

한편, 전술한 MLB 연구들은 대부분 직교 다중접속(orthogonal multiple access) 기반의 전송 구조를 전제하고 있으며, 물리 계층의 다중접속 기법과 부하 분산을 교차 계층에서 공동 제어하려는 시도는 소수에 머물러 있다. 부하 분산을 목적으로 단말을 인접

셀로 강제 핸드오버 시키는 행위는 해당 단말의 수신 품질 하락을 수반하므로, 전송 계층에서의 간섭 제어가 뒷받침되지 않으면 시스템 전체의 처리량 감소로 이어진다. 비직교 다중접속 환경에서 사용자 접속과 자원 할당을 공동 최적화하여 이러한 품질 저하를 보상하려는 연구[30]가 보고되었으나, SDMA에서 NOMA, RSMA로 이어지는 다중접속 기법의 발전 과정에서 각 기법이 제공하는 고유한 간섭 관리 구조와 MLB의 시너지는 충분히 탐구되지 않았다. 구체적으로, RSMA의 공통 스트림 전력 분할 비율을 적응적으로 조절하면 강제 핸드오버에 따른 셀 경계 사용자의 수신 품질 저하를 공통 메시지의 간섭 흡수 능력으로 보상할 수 있으나, 이러한 물리 계층의 RSMA 분할 비율과 네트워크 계층의 CIO를 교차 계층에서 공동으로 최적화한 연구는 현재까지 부재하다. 이상의 문헌 분석을 종합하면,

(i) 모델 기반 강화학습의 MLB 적용 부재, (ii) RSMA 분할 비율과 CIO의 교차 계층 공동 최적화 부재라는 두 연구 공백이 확인되며, 본 논문은 이를 통합적으로 다루는 프레임워크를 제시한다.

3. 시스템 모델

3.1. 네트워크 및 채널 모델

그림 1과 같이 M 개의 기지국과 U 명의 사용자로 구성된 다중 셀 하향링크 네트워크에서 1-layer RSMA를 활용한다. 송신 안테나의 공간 자유도를 초과하여 사용자가 접속된 과부하 환경을 고려하여, 각 기지국은 전송 시점마다 전체 사용자 집합 중 특정 사용자 집합 $K \subseteq U$ 를 선택한다. 해당 사용자들을 기반으로 해 공통으로 해독할 수 있는 공통 스트림과 개별 사용자를 위한 전용 스트림을 중첩하여 전송한다. 각 기지국은 N_t 개의 송신 안테나를 등간격 선형 배열(Uniform Linear Array, ULA)로 구성하며, 각 사용자는 단일 안테나를 사용한다. 기지국과 사용자 사이의 하향링크 채널 벡터 $\mathbf{h}_{m,u} \in \mathbb{C}^{N_t \times 1}$ 는 공간 상관 Rayleigh 페이딩 모델을 따르며 다음과 같이 표현된다 [31, 32].

$$\mathbf{h}_{m,u} = \sqrt{\zeta_{m,u}} \mathbf{R}_m^{1/2} \mathbf{g}_{m,u} \quad \mathbf{g}_{m,u} \sim \mathcal{CN}(0, \mathbf{I}_{N_t}). \quad (1)$$

여기서 $\zeta_{m,u}$ 는 경로손실과 채널도인을 포함하는 대규모 감쇠 계수이며, $\mathbf{g}_{m,u}$ 는 각 원소가 독립적이고 동일하게 분포된 소규모 페이딩 벡터이다. $\mathbf{R}_m$ 는 ULA 송신 안테나의 공간 상관행렬로, 다음과 같은 지수형 모델을 따른다.

$$[\mathbf{R}_m]_{p,q} = \rho_m^{|p-q|}, \quad \forall p, q \in 1, \dots, N_t. \quad (2)$$

p 와 q 는 ULA를 구성하는 송신 안테나의 인덱스이며, 상관 계수 ρ_m 이 0이면 독립 페이딩, 1에 가까울수록 강한 공간 상관을 나타낸다. 대규모 감쇠 계수 $\zeta_{m,u}$ 는 다음과 같이 주어진다.

$$\zeta_{m,u} = 10^{-(\text{PL}_{m,u}^{\text{NLOS}} + X_{m,u}^{\text{SF}})/10}, \quad X_{m,u}^{\text{SF}} \sim \mathcal{N}(0, \sigma_{\text{SF}}^2). \quad (3)$$

이때 $X_{m,u}^{\text{SF}}$ 는 장애물에 의한 신호 차폐 효과를 반영하는 음영 페이딩 성분으로, 평균이 0이고, 분산이 σ_{SF}^2 인 가우시안 분포를 따른다. $\text{PL}_{m,u}^{\text{NLOS}}$ 는 3GPP UMi(urban micro) 모델에 기반하여 비가시거리(Non-Line-of-Sight, NLOS) 경로 손실이다 [33]. 도심지 환경의 건물 차단 효과를 직접 반영하기 위해 명시적 NLOS 수식을 일괄 적용하며, 다음과 같이 정의된다.


$$\text{PL}_{m,u}^{\text{NLOS}} = 35.3 \log_{10}(d_{m,u}^{3\text{D}}) + 22.4 + 21.3 \log_{10}(f_c) - 0.3(h_u - 1.5). \quad (4)$$

여기서 $d_{m,u}^{3\text{D}}$ 는 기지국과 사용자 간의 3차원 거리이며, f_c 는 중심 주파수, h_u 는 사용자의 안테나 높이다. 단, 사용자와 기지국이 너무 가까워 발생하는 경로 손실의 물리적 역전 현상을 방지하기 위해 사용자는 기지국으로부터 일정 거리 이상 이격되어 있다고 가정한다.

다중 셀 네트워크 환경에서는 채널 피드백 지연 및 측정 잡음 등으로 인해 기지국이 완벽한 채널 상태 정보를 획득하는 것이 불가능하다. 이러한 지연에 따른 채널의 불확실성을 반영하고자 가우스-마르코프(Gauss-Markov) 형태의 모델을 사용하며 다음과 같이 정의한다 [34].

$$\hat{\mathbf{h}}_{m,u} = \sqrt{1-\alpha} \mathbf{h}_{m,u} + \sqrt{\alpha} \mathbf{e}_{m,u}. \quad (5)$$

기지국이 획득한 추정 채널 벡터 $\hat{\mathbf{h}}_{m,u}$ 는 실제 채널 벡터 $\mathbf{h}_{m,u}$ 와 추정 오차 벡터 $\mathbf{e}_{m,u}$ 의 가중 선형 결합으로 구성된다. $\alpha \in [0, 1]$ 는 CSIT 불확실성의 정도를 조절하는 통계적 매개변수이며, $\alpha = 0$ 은 완벽한 CSIT를 의미한다.



[그림 1] RSMA 기반 다중 셀 MIMO 하향링크 시스템 모델

3.2. 저복잡도 사용자 선택 기반 RSMA 전송 모델

3.1에서 정의된 바와 같이, 기지국은 선정된 사용자 집합을 대상으로 전송을 수행한다. 기지국에 연결된 모든 사용자를 대상으로 1-layer RSMA를 일괄 적용할 경우, 수신단에서 제거되지 못한 전용 스트림 간의 잔여 간섭이 급증할 뿐만 아니라, 가장 열악한 채널 상태를 가진 사용자의 수신 신호 대 간섭 및 잡음비(Signal to Interference plus Noise Ratio, SINR)에 의해 공통 스트림의 달성 가능한 전송률이 제한되는 병목 현상이 발생한다. 이는 최종적으로 전체 시스템의 총합 전송률을 감소한다. 최적의 사용자 부분 집합을 찾는 완전 탐색(exhaustive Search) 기반 기법[13]은 이러한 전송률 열화를 방지할 수 있으나, 시스템 규모에 비례하여 기하급수적인 연산 복잡도를 수반하므로 밀리초 단위의 실시간 제어가 요구되는 동적 통신 환경에 적용하기가 가하다. 따라서 연산 지연을 최소화하여 실시간 스케줄링을 보장할 수 있는 저복잡도 사용자 선택 알고리즘을 기반으로 RSMA 전송 모델을 정의한다.

기지국 m 이 선택한 사용자 집합 K_m 를 대상으로 전송하는 하향링크 1-layer RMSA 송신 신호 $\mathbf{x}_m \in \mathbb{C}^{N_t \times 1}$ 는 다음과 같이 표현된다 [3].

$$\mathbf{x}_m = \sqrt{p_{m,c}} \mathbf{w}_{m,c} s_{m,c} + \sum_{u \in K_m} \sqrt{p_{m,u}} \mathbf{w}_{m,u} s_{m,u}. \quad (6)$$

$p_{m,c}$ 와 $p_{m,u}$ 는 각각 3.1에서 정의된 바와 같이, 기지국은 선정된 사용자 집합을 대상으로 전송을 수행한다. 각각 공통 스트림과 전용 스트림의 송신 전력이다. 기지국의 총 송신 전력을 P_m , 전력 분할 비율을 $\eta_m \in [0, 1]$ 이라 할 때, 공통 스트림 전력은 $p_{m,c} = \eta_m P_m$ 이다. 선택된 사용자들에 대한 전용 스트림 송신 전력은 시스템의 연산 복잡도를 최소화하기 위해 $p_{m,u} = \frac{(1-\eta_m)P_m}{|K_m|}$ 로 동일하게 할당한다. $s_{m,c}$ 와 $s_{m,u}$ 는 각각 공통 스트림과 전용 스트림을 나타내며, $\mathbf{w}_{m,c}$ 와 $\mathbf{w}_{m,u}$ 는 각각 공통 및 전용 스트림을 위한 정규화된 프리코딩 벡터($\|\mathbf{w}\|^2 = 1$) 이다.

사용자 u 의 수신 신호 y_u 는 다음과 같이 모델링 된다.

$$y_u = \mathbf{h}_{m,u}^H \mathbf{x}_m + \sum_{n \in M, n \neq m} \mathbf{h}_{n,u}^H \mathbf{x}_n + z_u. \quad (7)$$

여기서 $\mathbf{h}_{m,u}$ 는 기지국으로부터의 채널 벡터, 두 번째 항은 타 기지국으로부터의 셀간 간섭을 나타내며, z_u 는 가산성 백색 가우시안 잡음(Additive White Gaussian Noise, AWGN) 샘플이며, 평균이 0이고 분산이 σ_u^2 인 복소 가우스 분포를 따른다. 공통 프리코더 $\mathbf{w}_{m,c}$ 는 선택된 모든 사용자가 공통 스트림을 원활히 수신할 수 있도록 집합 K_m 채널의 정규화된 합으로 구성된다.

$$\mathbf{w}_{m,c} = \frac{\sum_{u \in K_m} \hat{\mathbf{h}}_{m,u}}{\left\| \sum_{u \in K_m} \hat{\mathbf{h}}_{m,u} \right\|}. \quad (8)$$

반면, 전용 스트림은 사용자 간 간섭을 소거하기 위해 ZF(Zero-Forcing) 기반의 선형 프리코딩을 적용한다. 선택된 집합의 결합 추정 채널 행렬을 $\hat{\mathbf{H}}_m$ 라 할 때, 전용 스트림을 위한 ZF 프리코딩 행렬 $\mathbf{W}_m$ 은 다음과 같이 정의된다 [35, 36].

$$\mathbf{W}_m = \hat{\mathbf{H}}_m^H (\hat{\mathbf{H}}_m \hat{\mathbf{H}}_m^H)^{-1}. \quad (9)$$

기지국은 위 행렬의 각 열벡터를 단위 노름으로 정규화하여 전용 프리코더 $\mathbf{w}_{m,u}$ 를 획득한다. 그러나 채널 상관성이 높은 사용자들이 공간 다중화될 경우, ZF 행렬의 불량 조건 (ill-conditioned) 문제로 인해 역행렬 연산 과정에서 빔포밍 성능이 감소한다. 따라서 기지국은 프리코더 설계 전, 상호 직교성이 확보된 사용자 집합을 선별하는 저복잡도 스케줄링 과정을 수행한다. 이를 위해 임의의 사용자 쌍 $u, v \in U_m$ 간의 공간 상관도를 다음과 같이 정의한다.

$$\text{corr}(u, v) = \frac{|\hat{\mathbf{h}}_{m,u}^H \hat{\mathbf{h}}_{m,v}|}{\|\hat{\mathbf{h}}_{m,u}\| \|\hat{\mathbf{h}}_{m,v}\|}. \quad (10)$$

기지국은 공간 상관도를 기준으로 사용자 간 직교성을 보장한다. 그러나 단순히 채널 이득을 갖는 사용자들만을 선택할 경우, 기지국 채널 환경이 좋은 특정 사용자에게만 자원이 독점되는 문제가 발생한다. 이를 방지하고 네트워크 전반의 공정성을 확보하기 위해, 기지국은 매 선택 단계 I 에서 직교성 제약을 만족하는 후보군 중 PF 지표가 가장 높은 사용자 u_r^* 를 스케줄링 대상으로 선택한다.

$$\begin{aligned} u_r^* &= \underset{u \in U_m, u \notin K_m^{(I-1)}}{\text{argmax}} \quad \Omega_{m,u}, \\ \text{s.t } \max_{u \in K_m^{(I-1)}} \text{corr}(u, v) &\leq \delta_{\text{th}}. \end{aligned} \quad (11)$$

$\Omega_{m,u}$ 는 사용자 u 의 PF 지표이며, δ_{th} 는 허용 가능한 최대 상관도 임계값이다. 위 과정을 반복하여 사용자 집합을 구성한다. 수신단은 SIC 과정을 통해 신호를 복호화 한다. 이때 Perfect SIC 상황이라고 가정한다. 사용자 집합의 사용자는 먼저 전용 스트림들을 모두 간섭으로 취급하여 공통 스트림 $\mathbf{w}_{m,c}$ 을 해독한다. 이때 사용자 u 가 겪는 공통 스트림 SINR $\gamma_{m,u}^{(c)}$ 는 다음과 같이 주어진다.

$$\gamma_{m,u}^{(c)} = \frac{p_{m,c} |\mathbf{h}_{m,u}^H \mathbf{w}_{m,c}|^2}{\sum_{j \in K_m} p_{m,j} |\mathbf{h}_{m,u}^H \mathbf{w}_{m,j}|^2 + I_u + \sigma_u^2}. \quad (12)$$

이때 I_u 는 타 기지국으로부터의 누적 셀 간 간섭 전력이며, σ_u^2 는 사용자 수신기에서의 AWGN 분산을 나타낸다. 공통 스트림은 선택된 사용자 집합 전원이 복호 가능해야 하므로, 기지국의 공통 스트림 전송률 $R_m^{(c)}$ 는 집합 내 최소 SINR에 의해 다음과 같이 결정된다.

$$R_m^{(c)} = B \log_2(1 + \min_{u \in K_m} \gamma_{m,u}^{(c)}). \quad (13)$$

여기서 B 는 시스템 대역폭이다. 공통 스트림을 성공적으로 해독한 사용자 u 는 수신 신호에서 공통 스트림 성분을 제거한 후 자신의 전용 스트림 $s_{m,u}$ 를 해독한다. 해당 전용 스트림 수신 SINR $\gamma_{m,u}^{(p)}$ 는 다음과 같다.

$$\gamma_{m,u}^{(p)} = \frac{p_{m,u} |\mathbf{h}_{m,u}^H \mathbf{w}_{m,u}|^2}{\sum_{j \in K_m, j \neq u} p_{m,j} |\mathbf{h}_{m,u}^H \mathbf{w}_{m,j}|^2 + I_u + \sigma_u^2}. \quad (14)$$

이에 따른 사용자 u 의 전용 스트림 전송률 $R_{m,u}^{(p)}$ 은 다음과 같이 정의된다.

$$R_{m,u}^{(p)} = B \log_2(1 + \gamma_{m,u}^{(p)}). \quad (15)$$

기지국 m 의 총합 전송률 R_m 은 공통 스트림과 전용 스트림 전송률의 합으로 구성된다.

$$R_m = R_m^{(c)} + \sum_{u \in K_m} R_{m,u}^{(p)}. \quad (16)$$

3.3. A3 기반 핸드오버 모델

핸드오버는 3GPP Event A3 규칙에 따라 수행되며 [17, 37], 각 사용자는 측정할 수 있는 셀들 중 현재 서빙(serving) 셀을 제외한 셀을 대상(target) 셀 후보로 고려한다. 사용자 u 에 대한 대상 셀 t 와 서빙 셀 p 사이의 핸드오버 조건은 다음과 같이 정의된다.

$$\text{RSRP}_{n,u} + O_{c,n} - Hys \geq \text{RSRP}_{p,u} + O_{c,p} + O_{A3}. \quad (17)$$

$\text{RSRP}_{n,u}$ 와 $\text{RSRP}_{p,u}$ 는 각각 사용자가 측정한 대상 셀과 서빙 셀의 참조 신호 수신 전력(Reference Signal Received Power, RSRP)이며, 이때 RSRP 측정값은 소규모 페이딩에 따른 단기 변동을 완화하기 위해 Layer 3 필터링이 적용된 값으로 가정한다. $O_{c,p}$ 와 $O_{c,n}$ 은 각각 대상 셀과 서빙 셀의 적용되는 CIO로, 셀 간 접속 경계를 조정하여 부하 분산을 유도하는 제어 파라미터이다. Hys 는 단기적인 신호 변동에 의한 핑퐁(ping-pong) 핸드오버 현상을 억제하기 위한 히스테리시스 마진, O_{A3} 는 A3 오프셋을 나타낸다. 해당 조건이 TTT 구간 동안 연속적으로 만족할 때 핸드오버가 수행되며, 이를 통해 순간적 신호 변동에 의한 불필요한 핸드오버를 방지한다 [38].

3.4. 처리량 및 부하 모델

2.2절에서 정의한 RSMA 전송 모델을 통해 사용자별 달성 가능 전송률이 산정되며, 이를 바탕으로 네트워크 처리량과 기지국 부하를 정의한다. 본 연구에서 네트워크 처리량은 물리 계층의 달성 가능 전송률이 아니라, 트래픽 수요와 버퍼 내 전송 가능 데이터 양을 고려한 실제 전송한 처리량을 기준으로 산정된다.

기지국 m 에 연결된 사용자 집합을 u_m 라 하면, 네트워크 총합 처리량은 다음과 같이 정의된다.

$$T = \sum_{m \in M} \sum_{u \in U_m} T_{m,u} \quad (18)$$

$T_{m,u}$ 는 사용자 u 의 실제 전송 처리량을 나타낸다. 핸드오버 기반 부하 분산을 수행하기 위해서는 기지국별 혼잡 수준을 정량화하는 부하 지표가 필요하다. 본 연구에서는 하향 링크 PRB 사용률을 기지국 부하로 정의한다 [39]. 측정 구간 W 에 대한 기지국 m 의 부하는 다음과 같다.

$$l_m = \frac{\sum_{\tau \in W} N_m^{\text{used}}(\tau)}{\sum_{\tau \in W} N_m^{\text{tot}}(\tau)}. \quad (19)$$

여기서 $N_m^{\text{used}}(\tau)$ 와 $N_m^{\text{tot}}(\tau)$ 는 각각 해당 구간 내 시점 τ 에서 기지국 m 이 데이터 전송에 사용한 하향링크 PRB 수와 전체 가용 하향링크 PRB를 나타낸다. $l_m \in [0, 1]$ 이며, 측정 구간을 사용함으로써 단일 시점에서의 순간적 변동을 완화한다. RSMA 전송에서는 공통 스트림과 개별 스트림이 동일한 PRB를 공유하지만, PRB 사용량은 물리 자원의 점유 여부를 기준으로 산정하므로 해당 PRB는 한 번만 계산된다. RSMA에 의한 스펙트럼 효율 향상은 동일 PRB에서의 처리량 증가로 나타나며, 이는 T 를 통해 반영된다.

3.5. 문제 정의

다중 셀 네트워크에서 트래픽 수요는 공간적·시간적으로 불균일하게 분포한다. 채널 품질에 기반한 사용자-기지국 접속은 특정 기지국에 부하가 집중되는 결과를 초래할 수 있으며, 과부하 기지국에서는 사용자당 할당 가능한 자원이 감소하여 개별 처리량이 저하된다. 동시에, 저부하 기지국의 자원은 활용되지 않아 네트워크 전체의 자원 효율 또한 저하된다. 이처럼 기지국 간 부하 분포와 네트워크 처리량은 사용자 접속 구성을 통해 밀접하게 결합해 있으며, 네트워크 자원의 효율적 활용을 위해서는 이를 동시에 고려하는 최적화 문제의 정의가 필요하다.

기지국 간 부하 불균형 지표를 다음과 같이 정의한다.

$$\begin{aligned}\bar{l} &= \frac{1}{|M|} \sum_{m \in M} l_m, \\ \sigma_l &= \sqrt{\frac{1}{|M|} \sum_{m \in M} (l_m - \bar{l})^2}.\end{aligned}\tag{20}$$

$\bar{l}$ 는 평균 기지국 부하이며, σ_l 가 작을수록 기지국 간 부하가 균등하게 분포됨을 의미한다. 네트워크 처리량 T 과 부하 불균형 σ_l 는 서로 다른 척도를 가지므로, 두 항을 동일한 목적함수에서 고려하기 위해 정규화된 지표를 사용한다. 정규화된 처리량과 부하 불균형은 각각 다음과 같이 정의된다.

$$\tilde{T} = \min\left(1, \max\left(0, \frac{T}{T_{\text{ref}}}\right)\right).\tag{21}$$

$$\tilde{\sigma} = \min\left(1, \max\left(0, \frac{\sigma_l}{\sigma_{\text{ref}}}\right)\right).\tag{22}$$


여기서 $\tilde{T}$ 와 $\tilde{\sigma}$ 는 정규화를 위한 기준 상수이다. 이를 바탕으로 네트워크 성능 목적 함수 J 를 다음과 같이 정의한다.

$$J = w_T \tilde{T} + w_L (1 - \tilde{\sigma}). \quad (23)$$

가중치 $w_T, w_L \in [0, 1]$ 는 $w_T + w_L = 1$ 을 만족하며, 두 성능 지표간의 균형을 조절한다. 위 목적 함수는 사용자 이동, 트래픽 수요 변화, 채널 상태 변동 및 핸드오버 결과를 반영하여 네트워크 처리량과 부하 균형을 함께 평가하기 위한 기준으로 사용된다. 다음 장에서는 위 목적을 달성하기 위한 모델 기반 강화학습 기반 제어 기법을 제안한다.

4. TD-MPC2 기반 자원 최적화 프레임워크

본 장에서는 다중 셀 무선 네트워크 환경에서 시스템 전송률 극대화와 기지국 부하 분산을 동시에 달성하는 교차 계층 자원 최적화 프레임워크를 제안한다. 그림 2는 제안하는 프레임워크의 전체 구조도를 나타낸다. 해당 시스템은 시스템 변수 간의 상이한 제어 주기를 포괄하는 다중 시간 척도환경 모델, 비동기적 네트워크 제어를 위한 MDP 정식화, 그리고 잠재 공간(latent space) 역학(dynamics) 기반의 예측 제어 알고리즘으로 구성된다. 프레임워크의 구체적인 시스템 설계 및 알고리즘 세부 사항은 이어지는 하위절에서 순차적으로 기술한다.



[그림 2] 제안하는 TD-MPC2 기반 멀티 타임스케일 자원 최적화 프레임워크

4.1. 멀티 타임스케일 교차 계층 제어 구조

물리 계층의 RSMA 전력 분할 비율(Split ratio)과 네트워크 계층의 핸드오버 CIO는 시스템에 미치는 영향의 범위와 상태 변화 속도가 상이하다. 요구되는 제어 주기가 다른 파라미터들을 단일 타임스케일로 갱신하는 것은 제어 불안정성을 초래한다. 구체적으로, 고속 페이딩에 따른 동적인 간섭 제어가 요구되는 물리 계층의 제어 요구사항과 핑퐁 현상 및 시그널링 오버헤드를 억제하기 위해 장주기 갱신이 요구되는 네트워크 계층의 안정성 목표를 단일 주기 내에서 동시에 달성할 수 없다. 따라서 각 제어 요소의 물리적

특성을 반영하여 제어 주기를 분리하는 멀티 타임스케일 구조가 필수적이다. 본 연구에서는 이러한 특성을 반영한 멀티 타임스케일 교차 계층 제어 구조를 제안한다. 단기적인 무선 채널 변동에 적응하여 데이터 전송률을 향상하기 위해, RSMA 전송 비율은 의사결정 스텝 t 마다 환경에 적용되는 단기 제어를 수행한다. 반면, CIO는 모빌리티의 안정성을 위해 단기 주기의 T_c 배인 장기 스케일 단위로 갱신되며, 갱신 주기 사이에는 이전 제어값이 유지된다 [40]. 강화학습 에이전트는 매 스텝 결합 행동 벡터 a_t 를 결정하지만, 네트워크 환경은 파라미터에 할당된 갱신율(update rate)에 따라 이를 차등적으로 반영한다. 이처럼 상이한 스텝 주기를 갖는 제어 환경을 단일 MDP로 통합하여 정식화한다.

4.2. MDP 정식화

멀티 타임스케일 네트워크 제어 문제는 튜플 (S, A, P, r, γ) 로 정의되는 MDP로 정식화한다 [41]. 여기서 상태 전이 확률 $P(s_{t+1}|s_t, a_t)$ 는 무선 채널의 확률적 페이딩과 단말의 이동성에 종속되어 결정된다. 모델은 단일 중앙집중형 에이전트가 네트워크 전역의 관측 정보를 바탕으로 다중 셀의 자원 할당 및 부하 분산 제어 정책을 동시에 결정하는 구조를 갖는다.

4.2.1. 상태 공간

중앙집중형 에이전트는 매 의사결정 시각 t 에서 네트워크 전역의 상태를 단일 벡터 $s_t \in S$ 로 관측한다. 전역 상태 벡터는 다음과 같이 정의된다.

$$s_t = [l(t), \Delta l(t), q(t), \eta(t), c(t), \phi(t)]. \quad (24)$$

여기서 각 벡터는 $|M|$ 차원이며, 기지국 m 에 대응하는 상태 벡터의 각 성분은 다음과 같이 정의된다.

- $l_m(t)$: PRB 점유율로 정의되는 셀 부하
- $\Delta l_m(t)$: 네트워크 시스템 평균 부하 대비 상대적 부하 편차. 부하 불균형의 방향과 크기를 제공한다.
- $q_m(t)$: 현재 서비스를 제공하는 사용자 집합 내 최저 수신 SINR로 정의되는 병목
- 채널 품질
- $\eta_m(t), c_m(t)$: 현재 적용 중인 RSMA 분할 비율 및 CIO 값.
- $\phi_m(t) \in [0, 1]$: 다음 CIO 갱신 시점까지의 잔여 위상을 나타내는 시간 지표. 이를 통해 갱신 주기 내 현재 위치를 인지한다.

다차원 성분 간의 스케일 정합 및 학습 안정성을 위해 전역 상태 벡터의 모든 성분은 $[0, 1]$ 범위로 정규화되며, 이에 따른 전역 상태 공간의 차원은 $\dim(S) = 6|M|$ 이다.

4.2.2. 행동 공간

에이전트는 시각 t 마다 전체 시스템에 대한 결합 행동 벡터 $\mathbf{a}_t \in \mathcal{A}$ 를 산출한다. 기지국 m 에 대응하는 행동은 CIO 값과 RSMA 분할 비율로 구성된다. 전역 상태 벡터는 모든 기지국의 제어 입력을 결합한 형태로 다음과 같이 정의된다.

$$\mathbf{a}_t = [c_1(t), \eta_1(t), \dots, c_{|M|}(t), \eta_{|M|}(t)]. \quad (25)$$

$c_m(t)$ 는 $[-6, 6]$ dB 범위 내에서 결정되는 오프셋 변수이며, $\eta_m(t)$ 는 $[0.1, 0.9]$ 범위 내에서 RSMA 분할 비율을 결정한다. 단 도출된 행동은 앞서 정의한 멀티 타임스케일 구조에 따라, RSMA 분할 비율은 매 스텝 환경에 반영되지만, CIO는 $t \bmod T_C = 0$ 인 스텝에서만 갱신되며, 그 외 구간에서는 이전 갱신값으로 유지된다. 전체 행동 공간의 차원은 $\dim(\mathcal{A}) = 2|M|$ 이다.

4.2.3. 보상 함수

순간 보상(instantaneous reward) $r(t)$ 는 앞선 2.5절에서 정의된 네트워크 성능 목적 함수를 사용하여 다음과 같이 정의된다.

$$r(t) = \mathcal{J}(t). \quad (26)$$

본 연구에서는 목적 함수를 구성하는 가중치를 $w_T = 0.6$, $w_L = 0.4$ 로 설정하여, 최적화 균형을 추구하되 처리량 지표에 상대적인 가중을 부여하도록 보상을 구성하였다. 결과적으로 강화학습 에이전트의 궁극적인 목적은 단일 스텝의 즉각 보상을 얻는 것이 아니라, 제어 정책 π 을 통해 유한 시간 구간(finite time horizon) H_{hor} 동안 발생하는 기대 누적 할인 보상(expected cumulative discounted reward)을 최대화하는 것이다. 이를 달성하기 위한 최적 정책 π^* 의 탐색 목적 함수는 다음과 같이 정의된다.

$$\pi^* = \operatorname{argmax}_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{H_{\text{hor}}-1} \gamma^t r(t) \right]. \quad (27)$$

$\gamma \in [0, 1)$ 는 미래 보상의 가치를 조절하는 할인 인자(discount factor)이다.

4.3. TD-MPC2 알고리즘

다중 셀 네트워크 환경은 무선 채널의 확률적 변동과 사용자 이동성에 의해 복잡한 동역학을 가진다. 또한 멀티 타임스케일 구조의 이질적인 제어 주기는 정책 신경망의 단일 순방향 추론(forward inference)에 의존하는 근시안적 제어 방식으로는 시스템의 장기적 최적성을 달성하기 어렵다. 따라서 복합적인 시공간적 제약 조건 하에서 미래 상태를 예측하고 최적 행동을 도출하기 위해, 학습된 역학 모델로 미래 궤적을 사전에 시뮬레이션하는 모델 기반 강화학습 알고리즘인 TD-MPC2를 채택한다 [27, 42]. 해당 알고리즘은 환경의 상태 전이를 잠재 공간 상에서 예측함으로써 근시안적 의사결정의 한계를 극복하고, 가치 앙상블에 기반한 보수적 계획을 통해 제어의 안정성을 확립한다.

4.3.1. 월드 모델

TD-MPC2는 관측 데이터의 재구성 과정을 생략하고, 제어 결과 예측만을 목적으로 하는 잠재(latent) 세계 모델을 학습한다. 고차원 상태 벡터 s_t 를 원시 차원에서 직접 예측하는 것은 높은 공간 복잡도와 노이즈로 인해 비효율적이므로, 관측 인코더 h_θ 를 통해 상태를 저차원 잠재 표현 $z_t \in R^d$ 로 매핑한다 [25, 43].

$$z_t = \phi_\theta(s_t). \quad (28)$$

이러한 잠재 공간 투영은 제어와 무관한 변동 요인을 필터링하여 역학 모델이 유의미한 패턴에 집중하도록 유도하며, 동시에 저차원 공간에서의 재귀적 연산을 통해 다중 롤아웃(rollout)의 효율을 극대화하며, 다음과 같이 정의된다.

$$\begin{aligned} z_{t+1} &= f_\theta(z_t, a_t), \\ \hat{r}_t &= r_\theta(z_t, a_t), \\ \hat{q}_t &= Q_\theta(z_t, a_t), \\ \hat{a}_t &= \pi_\theta(z_t). \end{aligned} \quad (29)$$

잠재 역학 모델 f_θ 는 현재 잠재 상태 z_t 와 행동 a_t 로부터 차기 잠재 상태 z_{t+1} 를 예측함으로써, 환경의 상태 전이 확률 P 를 잠재 공간의 동역학으로 직접 투영하여 근사한다. 보상 예측기 r_θ 와 가치 네트워크 Q_θ 는 각각 순간 보상과 할인 누적 보상을 추정하며, 정책 사전 확률 π_θ 는 Q_θ 를 최대화하는 행동 분포를 추정하여 계획 단계의 탐색 효율을 높인다.

4.3.2. 잠재 공간 기반 계획

에이전트는 의사결정 시점에서 학습된 월드 모델을 활용하여 잠재 공간 내 온라인 궤적 추적을 수행한다. 이는 환경과 직접 부딪히며 시행착오를 겪어야만 하는 모델 프리 방식과 달리, 가상 환경에서의 사전 시뮬레이션을 통해 치명적인 성능 저하를 방지할 수

있다는 점에서 네트워크 자원 최적화에 효과적이다. 구체적으로, 모델 예측 경로 적분(model predictive path integral) 기반의 최적화를 통해 다음의 목적 함수를 최대화하는 행동 시퀀스를 탐색한다 [44].

$$G^{(n)} = \sum_{i=0}^{H_{\text{hor}}-1} \gamma^i \hat{r}_{t+i}^{(n)} + \gamma^{H_{\text{hor}}} Q_{\min}(\hat{z}_{t+H_{\text{hor}}}^{(n)}, \hat{a}_{t+H_{\text{hor}}}^{(n)}). \quad (33)$$

$\gamma^{H_{\text{hor}}} Q_{\min}(\hat{z}_{t+H_{\text{hor}}}^{(n)}, \hat{a}_{t+H_{\text{hor}}}^{(n)})$ 은 롤아웃 종단 시점의 기대 수익을 보전하기 위한 종단 가치 추정치이다. 가치 함수의 과대 추정 편향을 억제하기 위해 가치 네트워크 앙상블의 최솟값인 $Q_{\min}$ 을 사용하여 제어의 보수성과 안정성을 확보한다. 계획 위상에서는 현재 잠재 상태 z_t 로부터 다수의 후보 행동 시퀀스를 샘플링하고, 월드 모델 기반의 롤아웃을 통해 상위 엘리트(elite) 시퀀스를 선별하여 행동 분포의 모수를 반복적으로 정제한다.

4.3.3. 네트워크 최적화 및 파라미터 갱신

월드 모델의 구성요소 $\{\phi_\theta, f_\theta, r_\theta, Q_\theta\}$ 는 리플레이 버퍼 D 의 경험 데이터를 기반으로 공동 최적화된다. 전체 목적함수는 조인트 임베딩 예측(joint embedding prediction), 보상 예측, 가치 예측 손실의 선형 결합으로 정의된다.

$$L(\theta) = \sum_{t=0}^{H_{\text{hor}}} \lambda^t (\|f_\theta(z_t, a_t) - \text{sg}(\phi_\theta(s_{t+1}))\|_2^2 + L_r + L_Q). \quad (34)$$

여기서 sg 는 기울기 차단(stop-gradient) 연산자를 의미하며, 조인트 임베딩 예측 손실을 통해 역학 모델이 실제 환경의 전이를 잠재 공간 내에서 모사하도록 강제한다. 보상 및 가치 손실은 로그 변환 공간에서 이산 회귀(discrete regression)를 통해 최적화되어 보상 스케일 변동에 대한 강건성을 제공한다. 정책 사전 확률 π_θ 는 최대 엔트로피 목적 함수를 기반으로 가치 함수를 최대화하도록 별도로 갱신된다. 이러한 학습과 계획 단계는 매 제어 스텝에서 상호 보강적으로 작용하여, 향상된 예측 모델이 정교한 계획을 가능하게 하여 최적화된 행동이 양질의 데이터를 생성하는 선순환 구조를 형성한다.

5. 실험 방법 및 결과

본 연구에서는 제안하는 TD-MPC2 기반 자원 할당 기법의 시뮬레이션 환경을 정의하고, 베이스라인 기법들과의 주요 성능 비교, 제안 기법의 구조적 효율성 분석, 그리고 이질 트래픽 환경에서의 적용 평가 결과를 순차적으로 제시한다.

5.1. 실험 방법

제안 기법의 성능을 검증하기 위한 네트워크 시뮬레이션 환경은 3GPP UMi Street-Canyon 시나리오를 준수하며 [33, 45] 800m × 800m의 영역 내에서 격자 도로 환경으로 구현하였다. 해당 영역 내에 5개의 기지국이 250 m의 사이트 간 거리 (inter-site distance)를 두고 배치되며, 총 60개의 사용자가 분포한다. 기지국은 4개의 안테나를 활용하여 단일 수신 안테나를 지닌 사용자와 1-layer RSMA 통신을 수행한다. 현실 무선 채널 환경을 반영하기 위해 NLOS 경로손실 모델을 따르며, 불완전한 CSIT를 반영하기 위해 채널 오차율 $\alpha = 0.1$ 을 적용하였다. 도심지 네트워크의 동적 부하 분포 및 핸드오버 비대칭성을 모사하고자, 단말의 이동 속도를 저속 보행자부터 도심지 차량을 아우르는 세 가지 이질적 그룹으로 분류하여 실험을 수행하였다. 이외에 네트워크 파라미터는 표 1과 같다 [46].

제안하는 자원 할당 기법에 도입된 TD-MPC2 에이전트의 주요 하이퍼파라미터 설정은 표 2와 같다. 본 연구는 고차원 상태 공간의 특징 추출과 가치 함수의 과대평가 편향 억제를 위해 TD-MPC2 고유의 인코더-잠재 공간 구조 및 다중 가치 네트워크 앙상블을 활용하였다. 또한, 네트워크 환경의 동적 변화 추론 정확도와 연산 복잡도 간의 상충 관계를 고려하여, 플래닝 단계의 예측 구간 및 MPPI 반복 횟수 등의 최적화 파라미터를 표의 수치와 같이 본 연구의 목적에 맞게 제어하여 적용하였다. 제안 기법의 제어 성능을 검증하기 위해 다음과 같은 네 가지 기준(baseline) 환경을 대조군으로 설정하였다.

Parameter	Value
Network Configuration	
Deployment area	800 m x 800 m
Inter-site distance (ISD)	250 m
Number of Base stations/Total Users	5 / 60
Base station transmit power / Antenna gain	33 dBm / 5 dBi
Antenna configuration	4 x 1
Channel and Handover	
Carrier frequency / Bandwidth	3.5 GHz / 100 MHz
Pathloss / Shadowing	TR 38.901 NLOS / 7.82 dB
CSIT error factor	0.1
Hysteresis / Time-to-Trigger	3 dB / 320 ms
Traffic and Mobility	
Mobility / Traffic model	Street-grid / Constant bit rate
Data rate per User	8 Mbps
User speed groups	{0.5-1.5, 1.5-3.0, 4.0-8.0} m/s
User count per group	20

[표 1] 시뮬레이션 파라미터 설정

- **Fixed-action:** CIO 값을 0 dB로 유지하고, RSMA 분할 비율을 0.5로 고정하여 자원을 할당하는 정적 자원 관리 기법
- **PPO:** 클리핑(Clipping)된 목적 함수를 기반으로 정책을 업데이트하는 On-policy 모델 프리 알고리즘 [47]
- **SAC (Soft Actor-Critic):** 최대 엔트로피 강화학습 프레임워크를 기반으로 확률적 정책을 최적화하는 Off-policy 모델 프리 알고리즘 [48]
- **TD3 (Twin Delayed Deep Deterministic Policy Gradient):** 두 개의 Q-네트워크를 활용하여 가치 함수의 과대평가 편향을 보정하는 결정론적 Off-policy 알고리즘 [49]

Category	Hyperparameter	Value
Learning	Batch size	64
	Learning rate	5.4041e-4
	Discount factor	0.99
	Max gradient norm	20
Architecture	Encoder dim/layers	256 / 2
	Latent dim	256
	Value nets / dropout	5 / 0.01
	SimNorm dim	8
	Numer of bins (HL-Gauss)	101
Planning	Batch size	5
	Learning rate	4
	Discount factor	256
	Max gradient norm	64
Objective	Consistency loss scale	20
	Reward / Value loss scale	0.1 / 0.1

[표 2] TD-MPC2 하이퍼파라미터 설정


5.2. 실험 결과

5.2.1. 시스템 성능 평가 및 비교 분석


제안하는 TD-MPC2 기법과 3종의 모델 프리 베이스라인 기법 간의 학습 수렴성 및 최종 네트워크 제어 성능을 정량적으로 비교 분석한다. 모든 대조군 알고리즘은 충분한 학습 단계를 거쳐 성능이 포화 상태에 도달하였음을 확인하였다. 그림 3은 학습 단계에 따른 각 알고리즘의 누적 보상(episode return) 수렴 곡선을 나타낸다. 제안 기법인 TD-MPC2는 환경의 동역학을 내부적으로 모델링하는 잠재 공간 플래닝을 통해 베이스라인 대비 우수한 샘플 효율성을 달성하였다. 구체적으로, TD-MPC2는 약 1,500,000 step 부근에서 최종 성능의 95% 이상에 도달하며 안정적인 수렴 특성을 보였다. 반면, 가장 우수한 베이스라인인 PPO의 경우 유사한 성능 수준에 도달하기까지 약 2,

500,000 step 이상이 소요되었으며, SAC와 TD3는 학습 종료 시점인 3,600,000 step 까지도 제안 기법의 최종 성능에 미치지 못하였다. 이는 모델 기반 추론이 복잡한 다중 셀 네트워크 환경에서 최적 정책을 탐색하는 데 소요되는 시행착오를 절대적 시간 측면에서 효과적으로 단축했음을 입증한다.


제어 정책 수렴 이후의 주요 성능 지표인 처리량과 부하 불균형 결과는 각각 그림 4와 그림 5와 같다. 제안 기법은 359.64 Mbps의 처리량을 기록하며 Fixed-action(291.79 Mbps) 대비 23.25%의 개선을 달성하였다. 특히 가장 우수한 베이스라인인 PPO(340.37 Mbps)와 비교해서도 약 5.66%의 추가 처리량 이득을 확보하였다. 부하 분산 지표의 경우, 제안 기법은 0.149의 불균형도를 유지하며 Fixed-action(0.209) 대비 28.71%, PPO(0.178) 대비 16.29% 감소된 수치를 기록하여 자원 할당의 공평성을 제고하였다. 그림 6은 시스템 신뢰성 지표인 HOF 발생률을 나타낸다. 제안 기법 적용 시 HOF 발생률은 0.120으로 관측되어 Fixed-action(0.422) 대비 71.56% 급감하였다. PPO(0.046)가 수치상 가장 낮은 실패율을 기록하였으나, 이는 모빌리티 제어에 소극적으로 개입하여 부하 분산 성능이 열화된 결과로 분석된다. 반면 제안 기법은 처리량 및 부하 분산 측면에서 뚜렷한 성능 향상을 확보하면서도 시스템 안정성을 저해하지 않는 범위 내에서 최적의 제어 정책이 도출되었음을 확인하였다.




[그림 3] 학습 단계에 따른 에피소드 리턴 수렴 곡선



[그림 4] 시스템 처리량 비교



[그림 5] 셀 간 부하 불균형 비교




[그림 6] HOF 발생률 비교

5.2.2. 제안 기법의 효용성 분석


제안 기법의 제어 동작(action)별 기여도와 보상 함수 가중치 설정에 따른 성능 민감도를 평가하였다.

Action 공간 설계의 효용성: 그림 7, 8, 9는 개별 제어 동작의 성능 기여도를 나타낸다. 분할 비율만을 단독 제어한 경우(CIO w/o) 처리량이 제안 기법 대비 15.26% 하락하고 부하 불균형은 59.51% 악화되었다. 특히 HOF 발생률이 0.1378로 증가하여 제안 기법 대비 14.54% 악화되었는데, 이는 트래픽 분산을 위한 CIO 제어의 부재가 연결 신뢰성 하락으로 직결됨을 입증한다. 반면, CIO만을 단독 제어한 경우(Split w/o)는 0.147의 우수한 부하 분산 성능과 0.1147의 낮은 HOF를 보였으나, 처리량은 제안 기법 대비 3.90%(14.04 Mbps) 감소하였다. 이는 다중 도메인 제어가 단일 제어 대비 유의미한 성능 시너지를 창출함을 확증한다.


보상 가중치 민감도 분석: 그림 10은 처리량 최적화(w_{th})와 부하 분산(w_{load}) 가중치를 0.0에서 1.0까지 0.2 단위로 가변하며 수행한 성능 평가 결과이다. 실험 결과, w_{th} 가 0.4에서 0.6 사이인 구간에서 총 처리량은 345.21-359.64 Mbps, 부하 불균형도는 0.146-0.149 수준으로 관측되었다. 이는 해당 가중치 범위 내에서 지표 간의 상충 관계(trade-off)가 완화되어, 특정 지표의 급격한 성능 열화 없이 시스템이 안정적인 제어 정책을 유지할 수 있음을 의미한다. 반면, w_{th} 가 0.8 이상으로 설정된 처리량 편중 구간에서는 처리량이 318.27 Mbps로 하락하는 변곡점이 나타났다. 이는 부하 분산에 대한 보상이 부족해짐에 따라 특정 기지국으로의 단말 쏠림 현상이 발생하였고, 결과적으로 가용 자원의 포화 및 간섭 증가가 처리량을 저해한 것으로 분석된다. 또한 부하 분산 가중치(w_{load})가 0.6을 초과하는 구간($w_{th} \leq 0.2$)에서는 부하 불균형도가 0.140 수준으로 낮게 유지되었으나, 처리량이 최대 19.33%까지 손실되는 성능 저하가 관측되었다. 결론적으로 본 연구에서 학습에 채택한 가중치 비율(0.6 : 0.4)은 두 성능 지표가 적절한 균형을 이루며 전체 시스템 자원 효율을 극대화할 수 있는 유효한 설정값임을 입증한다.




[그림 7] 개별 제어 동작에 따른 처리량 비교



[그림 8] 개별 제어 동작에 따른 부하 불균형 비교



[그림 9] 개별 제어 동작에 따른 HOF 발생률 비교



[그림 10] 보상 가중치 변화에 따른 처리량 및 부하 불균형 성능 변화

5.2.3. 이질 트래픽 환경에서의 일반화 성능 평가


제안 기법이 학습된 환경과 상이한 조건에서도 일관된 제어 성능을 보장하는지 범용성 및 강건성을 검증하기 위한 일반화 성능 검증을 수행했다. 앞선 성능 평가가 모든 사용자들의 트래픽 패턴과 요구 전송률을 동일한 상태에서 다양한 이동 속도가 혼재된 환경에서의 시스템 제어 성능을 평가했다면, 본 실험에서는 모든 사용자의 이동 속도를 5.0 m/s로 고정하고, 그룹별 트래픽 발생 패턴 및 요구 전송률을 다르게 설정하여 환경 이질성에 대한 제어 정책의 적응력을 확인하였다. 구체적인 설정 값은 표 3와 같다. 트래픽 모델은 3개의 트래픽 그룹(Constant bit rate, Heavy-tailed ON-OFF, ON-OFF; 각 평균 8 Mbps)으로 구성하였다.

Parameter	Value
Number of User	60
Mobility Speed	5.0 m/s
Group 1 Traffic (20 Users)	Constant bit rate, 8 Mbps
Group 2 Traffic (20 Users)	Heavy-tailed ON/OFF, Mean 8 Mbps
Group 3 Traffic (20 Users)	ON/OFF, Mean 8 Mbps


[표 3] 이질 트래픽 그룹 파라미터 설정

제어 정책 수립 이후의 처리량과 부하 불균형 결과는 각각 그림 11과 그림 12와 같다. 제안 기법은 292.32 Mbps의 처리량을 기록하며 Fixed-action(264.76 Mbps) 대비 10.41%의 개선을 달성하였다. 본 환경에서 PPO(321.86 Mbps)가 수치상 가장 높은 처리량을 기록하였으나, 이는 부하 분산을 희생하여 처리량 극대화에 편향된 결과이다. 반면 부하 불균형 지표의 경우, 제안 기법은 0.189를 유지하며 Fixed-action(0.252) 대비 24.90%, PPO(0.214) 대비 11.64% 감소된 수치로 전체 알고리즘 중 가장 우수한 성능을 달성하였다. 이는 이질적인 트래픽이 혼재된 환경에서도 제안 기법이 자원 할당의 공정성을 가장 안정적으로 방어하였음을 입증한다. 그림 13은 HOF 발생률을 나타낸다. 제안 기법 적용 시 HOF 발생률은 0.159로 관측되어 Fixed-action(0.364) 대비 56.26% 급감하였다. PPO(0.075)가 수치상 가장 낮은 실패율을 기록하였으나, 이는 평풍 현상 회피를 위해 모빌리티 제어에 소극적으로 개입한 결과 전반적인 부하 분산 성능의 열화로 이어


진 것으로 해석된다. 대조적으로 제안 기법은 부하 분산 측면의 우수한 성능을 확보하는 동시에, 상이한 트래픽 환경 조건 속에서도 처리량과 네트워크 신뢰성 간의 균형을 도출하는 범용성을 입증하였다.



[그림 11] 이질 트래픽 환경에서의 처리량 비교



[그림 12] 이질 트래픽 환경에서의 부하 불균형 비교



[그림 13] 이질 트래픽 환경에서의 HOF 발생률 비교

6. 결론 및 토의

본 논문은 5G MIMO 네트워크에서 트래픽의 공간적 불균형과 셀 간 간섭에 대응하기 위해, RSMA 기반의 물리 계층 간섭 제어와 CIO 기반의 네트워크 계층 부하 분산을 공동으로 최적화하는 교차 계층 제어 프레임워크를 제안하였다. 3GPP UMi-Street Canyon 채널 모델과 단일 계층 RSMA 신호 처리 구조를 토대로, 시스템 과부하 조건에서 다중 사용자 제어의 자유도를 확보하기 위한 저복잡도 사용자 선택 기반 RSMA 전송 구조를 채택하였다. RSMA 전력 분할 비율과 CIO라는 이질적 제어 변수의 차이를 반영하여 멀티 타임스케일 갱신 구조를 설계하고 이를 MDP로 정식화하였으며, 이 다차원 교차 계층 최적화 문제의 제어기로 잠재 공간 내 역학 모델 학습과 온라인 궤적 계획을 결합한 모델 기반 강화학습 알고리즘인 TD-MPC2를 도입하였다. 시뮬레이션 기반 성능 평가 결과, TD-MPC2 기반 제어 에이전트는 내부 월드 모델을 활용한 잠재 공간 계획을 통해 PPO, SAC 등 기존 모델 프리 알고리즘 대비 빠른 수렴과 높은 샘플 효율성을 보였다. 정적 자원 관리 기준 대비 시스템 처리량 23.25% 향상과 부하 불균형도 28.71% 감소를 동시에 달성하여, 자원 효율성과 부하 공평성 간의 동시 최적화를 달성하였다. 이는 과부하 기지국의 사용자 일부를 인접 저부하 기지국으로 능동적으로 재배치함과 동시에, RSMA 분할 비율의 적응적 조절을 통해 간섭을 관리함으로써 처리량 손실을 최소화할 수 있음을 의미한다. 또한 제안하는 교차 계층 제어를 통해 달성한 균형 있는 부하 분산은 네트워크 전반의 운용 안정성을 확보하여, 핸드오버 실패율을 크게 낮추고 실제 환경에서 요구되는 높은 연결 신뢰성을 보장하는 결과로 이어졌다. 이질적 트래픽 조건에서도 일관된 성능 우위를 유지하여, 제안 기법이 특정 트래픽 분포에 과적합되지 않고 다양한 운용 조건에 대한 일반화 능력을 갖추고 있음을 확인하였다.

다만, 본 연구에는 다음의 한계가 존재한다. 첫째, 중앙집중형 에이전트 구조는 기지국 및 사용자 수 증가에 따라 상태·행동 공간이 확대되어, 대규모 네트워크로의 확장성 측면에서 제약이 있다. 둘째, CIO와 RSMA 분할 비율의 갱신 주기를 분리하는 멀티 타임스케일 제어를 도입하였으나, 실제 네트워크에서 나타나는 보다 다양한 시간 척도의 상호작용을 충분히 반영하지 못하였다. 셋째, RSMA 개별 스트림의 전력을 사용자 간 균등 분배하는 가정을 적용하였으므로, 사용자별 채널 상태를 반영한 전력 할당 최적화는 수행되지 않았다.

향후 연구에서는 본 프레임워크를 고도화하기 위해 다음의 방향으로 확장을 추진하고자 한다. 첫째, 중앙집중형 구조의 확장성 한계를 해소하기 위해 다중 에이전트 강화학

습 또는 연합 학습(federated learning) 구조를 도입하여, 제어 부하를 효율적으로 분산하고 대규모 네트워크 환경에 적응 가능한 계층적 의사결정 체계를 설계할 계획이다. 둘째, 물리 계층과 네트워크 계층 간의 시간적 비대칭성을 정교하게 다루기 위해 제어 주기를 계층적으로 분리하여 최적화하는 계층적 강화학습 구조를 검토하거나, 각 인터페이스의 동역학적 특성에 기반한 적응적 갱신 모델을 구축하여 제어 정밀도를 높이려고 한다. 셋째, 기존 개별 스트림의 균등 전력 할당 가정을 완화하고 사용자별 실시간 채널 품질을 반영한 스트림별 전력 최적화 기법을 RSMA 구조에 통합함으로써, 개별 사용자의 간섭 제거 성능을 극대화하고 주파수 효율을 추가적으로 개선할 방침이다. 최종적으로는 이러한 최적화 기법을 셀 프리 대규모 다중입출력(cell-free massive MIMO) 등 차세대 네트워크 아키텍처로 확장 적용하여, 초고밀도 환경에서도 셀 경계 효과를 극복하고 균일한 사용자 체감 품질을 보장하는 자원 관리 프레임워크를 구축하고자 한다.

참고문헌

- [1] Agiwal, M., Roy, A., and Saxena, N., "Next generation 5G wireless networks: A comprehensive survey," IEEE Communications Surveys and Tutorials, vol. 18, no. 3, pp. 1617-1655, 2016.
- [2] Saad, W., Bennis, M., and Chen, M., "A vision of 6G wireless systems: Applications, trends, technologies, and open research problems," IEEE Network, vol. 34, no. 3, pp. 134-142, 2020.
- [3] Mao, Y., Clerckx, B., and Li, V. O. K., "Rate-splitting multiple access for downlink communication systems: Bridging, generalizing, and outperforming SDMA and NOMA," EURASIP Journal on Wireless Communications and Networking, vol. 2018, no. 1, pp. 1-54, 2018.
- [4] Mao, Y., Dizdar, O., Clerckx, B., et al., "Rate-splitting multiple access: Fundamentals, survey, and future research trends," IEEE Communications Surveys and Tutorials, vol. 24, no. 4, pp. 2073-2126, 2022.
- [5] Clerckx, B., Mao, Y., Schober, R., et al., "Is NOMA efficient in multi-antenna networks? A critical look at next generation multiple access techniques," IEEE Open Journal of the Communications Society, vol. 2, pp. 1310-1343, 2021.
- [6] Mishra, A., Mao, Y., Dizdar, O., et al., "Rate-splitting multiple access for 6G— Part I: Principles, applications, and future works," IEEE Communications Letters, vol. 26, no. 10, pp. 2232-2236, 2022.
- [7] Li, Y., Qin, Z., and Li, G. Y., "Rethinking WMMSE: Can its complexity scale linearly with the number of BS antennas?," IEEE Transactions on Communications, vol. 71, no. 9, pp. 5321-5335, 2023.
- [8] Uchoa, A. L. N., De Lamare, R. C., and Soares, A. M., "Low-complexity linear precoding for rate-splitting multiple access in MISO systems," IEEE Wireless Communications Letters, vol. 9, no. 8, pp. 1317-1321, 2020.
- [9] Dizdar, O., Mao, Y., Han, W., and Clerckx, B., "Rate-splitting multiple access: A new frontier for the PHY layer of 6G," in Proceedings of the IEEE Vehicular

Technology Conference (VTC-Fall), pp. 1-7, 2021.

- [10] Aliu, O. G., Imran, A., Imran, M. A., and Evans, B., "A survey of self organisation in future cellular networks," *IEEE Communications Surveys and Tutorials*, vol. 15, no. 1, pp. 336-361, 2013.
- [11] Joudeh, H. and Clerckx, B., "Sum-rate maximization for linearly precoded downlink multiuser MISO systems with partial CSIT: A rate-splitting approach," *IEEE Transactions on Communications*, vol. 64, no. 11, pp. 4847-4861, 2016.
- [12] Joudeh, H. and Clerckx, B., "Robust transmission in downlink multiuser MISO systems: A rate-splitting approach," *IEEE Transactions on Signal Processing*, vol. 64, no. 23, pp. 6227-6242, 2016.
- [13] Yoo, T. and Goldsmith, A., "On the optimality of multiantenna broadcast scheduling using zero-forcing beamforming," *IEEE Journal on Selected Areas in Communications*, vol. 24, no. 3, pp. 528-541, 2006.
- [14] Elhattab, M., Assi, C., and Ghayeb, A., "Low-complexity user pairing and resource allocation for downlink cooperative RSMA networks," in *Proceedings of the IEEE Wireless Communications and Networking Conference (WCNC)*, pp. 1-6, 2024.
- [15] Li, L., Yin, H., Xu, W., et al., "Resource allocation for multi-carrier rate-splitting multiple access system," *IEEE Access*, vol. 8, pp. 42468-42480, 2020.
- [16] Chen, F.-J., Yeh, C.-F., and Lee, T.-S., "Proportional fair scheduling for rate-splitting multiple access," *IEEE Transactions on Vehicular Technology*, vol. 70, no. 4, pp. 3975-3980, 2021.
- [17] 3GPP, "Evolved Universal Terrestrial Radio Access (E-UTRA); Radio Resource Control (RRC); Protocol specification," 3GPP TS 36.331, 2023.
- [18] Kumar, M. and Kumar, R., "A novel fuzzy logic based load balancing routing scheme for 5G cellular networks," *Physical Communication*, vol. 42, p. 101150, 2020.
- [19] Abdulrahman, M., Almatouri, H., and Sali, A., "A survey on machine learning approaches for self-organizing cellular networks," *IEEE Communications Surveys and Tutorials*, vol. 21, no. 3, pp. 2804-2830, 2019.

- [20] Kibria, M. G., Nguyen, K., Villardi, G. P., et al., "Big data analytics, machine learning, and artificial intelligence in next-generation wireless networks," *IEEE Access*, vol. 6, pp. 32328-32338, 2018.
- [21] Mollel, M. S., Abubakar, A. I., Ozturk, M., et al., "Intelligent handover decision scheme using double deep reinforcement learning," *Physical Communication*, vol. 42, p. 101133, 2020.
- [22] Attiah, K., Sourour, E., and Hassanein, H. S., "Mobility load management in cellular networks: A deep reinforcement learning approach," *IEEE Transactions on Mobile Computing*, vol. 22, no. 10, pp. 6155-6169, 2023.
- [23] Salama, B., ElSawy, H., and Alouini, M.-S., "Self-optimized agent for load balancing and energy efficiency: A reinforcement learning framework with hybrid action space," *IEEE Open Journal of the Communications Society*, vol. 5, pp. 1012-1025, 2024.
- [24] Zhao, N., Ye, Z., Pei, Y., et al., "Multi-agent deep reinforcement learning for task offloading in group cooperative multi-access edge computing," *IEEE Transactions on Communications*, vol. 70, no. 9, pp. 6189-6202, 2022.
- [25] Hafner, D., Lillicrap, T., Ba, J., and Norouzi, M., "Dream to control: Learning behaviors by latent imagination," in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2020.
- [26] Hansen, N., Su, H., and Wang, X., "Temporal difference learning for model predictive control," in *Proceedings of the International Conference on Machine Learning (ICML)*, pp. 8387-8406, 2022.
- [27] Hansen, N., Su, H., and Wang, X., "TD-MPC2: Scalable, robust world models for continuous control," in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024.
- [28] Feriani, A. and Hossain, E., "Single and multi-agent deep reinforcement learning for AI-enabled wireless networks: A tutorial," *IEEE Communications Surveys and Tutorials*, vol. 23, no. 2, pp. 1226-1252, 2021.
- [29] Polese, M., Bonati, L., D'Oro, S., et al., "Empowering the Open RAN ecosystem with model-based reinforcement learning," in *Proceedings of the IEEE INFOCOM Workshops*, pp. 1-6, 2024.

- [30] Wang, Z., Li, M., Liu, R., et al., "Deep reinforcement learning for joint user association and resource allocation in NOMA-based 5G networks," *IEEE Transactions on Wireless Communications*, vol. 19, no. 12, pp. 8305-8319, 2020.
- [31] Tse, D. and Viswanath, P., *Fundamentals of Wireless Communications*, Cambridge University Press, 2005.
- [32] Goldsmith, A., *Wireless Communications*, Cambridge University Press, 2005.
- [33] 3GPP, "Study on channel model for frequencies from 0.5 to 100 GHz," 3GPP TR 38.901, V16.1.0, 2020.
- [34] Heath, R. W. Jr. and Lozano, A., *Foundations of MIMO Communication*, Cambridge University Press, 2018.
- [35] Spencer, Q. H., Swindlehurst, A. L., and Haardt, M., "Zero-forcing methods for downlink spatial multiplexing in multiuser MIMO channels," *IEEE Transactions on Signal Processing*, vol. 52, no. 2, pp. 461-471, 2004.
- [36] Joham, M., Utschick, W., and Nossek, J. A., "Linear transmit processing in MIMO communications systems," *IEEE Transactions on Signal Processing*, vol. 53, no. 8, pp. 2700-2712, 2005.
- [37] 3GPP, "NR; Requirements for support of radio resource management," 3GPP TS 38.133, 2022.
- [38] 3GPP, "NR; Physical layer procedures for data," 3GPP TS 38.214, V17.0.0, 2022.
- [39] Lobinger, A., Stefanski, S., Jansen, T., and Balan, I., "Load balancing in downlink LTE self-optimizing networks," in *Proceedings of the IEEE Vehicular Technology Conference (VTC-Spring)*, pp. 1-5, 2011.
- [40] Borkar, V. S., *Stochastic Approximation: A Dynamical Systems Viewpoint*, Cambridge University Press, 2008.
- [41] Sutton, R. S. and Barto, A. G., *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.
- [42] Moerland, T. M., Broekens, J., Plaat, A., and Jonker, C. M., "Model-based reinforcement learning: A survey," *Foundations and Trends in Machine Learning*, vol. 16, no. 1, pp. 1-118, 2023.

- [43] Hafner, D., Pasukonis, J., Ba, J., and Lillicrap, T., "Mastering diverse control tasks through world models," *Nature*, vol. 640, no. 8059, pp. 647-653, 2025.
- [44] Williams, G., Aldrich, A., and Theodorou, E. A., "Model predictive path integral control: From theory to parallel computation," *Journal of Guidance, Control, and Dynamics*, vol. 40, no. 2, pp. 344-357, 2017.
- [45] 3GPP, "Further advancements for E-UTRA physical layer aspects," 3GPP TR 36.814, V9.2.0, 2017.
- [46] ITU-R, "Guidelines for evaluation of radio interface technologies for IMT-Advanced," ITU-R M.2135-1, 2009.
- [47] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., and Klimov, O., "Proximal policy optimization algorithms," *arXiv:1707.06347*, 2017.
- [48] Haarnoja, T., Zhou, A., Abbeel, P., and Levine, S., "Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor," in *Proceedings of the International Conference on Machine Learning (ICML)*, pp. 1861-1870, 2018.
- [49] Fujimoto, S., Hoof, H., and Meger, D., "Addressing function approximation error in actor-critic methods," in *Proceedings of the International Conference on Machine Learning (ICML)*, pp. 1587-1596, 2018.

Reinforcement Learning-Based Resource Optimization in 5G MIMO Networks Using RSMA

Ji myeong Kim

Department of Information Convergence Engineering
Pusan National University

Abstract

In 5G MIMO networks, adaptive control is essential to handle dynamic fluctuations from user mobility and inter-cell interference. While Rate-Splitting Multiple Access (RSMA) effectively mitigates interference, conventional optimization schemes incur high computational complexity. Furthermore, physical-layer control alone cannot ensure global network optimization, requiring joint consideration with network-layer load balancing. This paper proposes a Reinforcement Learning (RL)-based cross-layer resource optimization framework. By adopting a low-complexity RSMA structure incorporating a proportional fairness metric and channel spatial correlation, the proposed scheme jointly optimizes the Cell Individual Offset (CIO) and RSMA split ratio to enhance both throughput and load distribution. The framework achieves higher sample efficiency than conventional model-free RL algorithms, increasing total throughput by 23.25% over the baseline. It also enhances system reliability, reducing load imbalance and handover failure rates by 28.71% and 71.56%, respectively. Finally, stable performance under heterogeneous traffic validates its robustness for practical 5G MIMO deployments.